

Selective Verification with Label-Prior Debiasing for Bias-Aware Multimodal QA

선택적 검증과 Label-Prior 편향 제거를 결합한 편향 인지형 멀티모달 QA 전략

팀 나프탈렌

박준서 | 동국대학교 인공지능전공

aaa0342@dgu.ac.kr

강민제 | 동국대학교 정보통신학과

2022112070@dgu.ac.com

이형준 | 동국대학교 컴퓨터Ai학과

lhj71485750@gmail.com

Contents

1. Experiment Enviroment
2. Initial Approach
3. Intermediate Approach
4. Final Approach
5. Conclusion
6. Resources

1. Experiment Environment

Hardware Specs

- CPU: AMD EPYC 7R13 Processor, 8 cores / 16 threads
- Memory: 124GB RAM
- GPU: NVIDIA L40S 48GB
- Storage: 549GB workspace storage
- OS: Ubuntu 24.04.4 LTS

Key Library Versions

- transformers : 5.13.0.dev0
- torch : 2.6.0+cu124
- torchaudio : 2.6.0+cu124
- torchvision : 0.21.0+cu124
- python : 3.10.0
- cuda : 12.4 (PyTorch CUDA build), NVIDIA Driver 580.159.03

Execution Platform

- Platform: Lightning AI Studio
- Runtime: Cloud GPU environment

1. Experiment Environment

Qwen2.5-VL-7B

- 7B급 오픈소스 Vision-Language Model
- 이미지와 텍스트를 함께 입력받아 시각 질의응답(VQA) 수행 가능
- 객체, 인물, 장면뿐 아니라 문서, 차트, 레이아웃, 이미지 내 텍스트 이해에 강점
- 다양한 해상도 이미지를 처리하는 dynamic resolution 기반 구조
- 비교적 가볍고 추론 속도가 빨라 실험용 baseline 모델로 사용

Qwen3-VL-8B

- 8B급 오픈소스 Vision-Language Model
- Qwen2.5-VL 대비 텍스트 이해, 시각 추론, 공간 이해 능력이 강화된 후속 계열 모델
- 이미지 속 상황을 보고 질문과 선택지를 함께 판단하는 멀티모달 추론에 적합
- 긴 문맥 처리와 복합적인 이미지-텍스트 관계 이해에 강점
- 성능과 추론 비용 간의 균형이 우수하여 최종 추론 모델로 채택

2. Initial Approach

Initial Approach: Naïve Multimodal Reasoning

- Input: {이미지, context, question, choices}
- 단일 프롬프트를 통해 한 줄 내외의 간단한 추론과 함께 답을 구하도록 유도하는 설계
- 5가지 prompt engineering 기법에 대한 비교 분석 수행
 - one-shot : baseline + one-shot example
 - context-first : baseline + context 우선 추론 프롬프트
 - bias-sensitive : baseline + 편향 방지 프롬프트
 - evidence rule : baseline + evidence 출력 강제
 - 공격/보수 + judge : 공격적·보수적 프롬프트로 각각 답변을 생성한 뒤, 결과가 다르면 Judge 프롬프트로 최종 답변을 결정

2. Initial Approach

Initial Approach: Naïve Multimodal Reasoning

- Prompt Engineering에 따른 성능 비교
 - 1) baseline : 가장 기본적인 프롬프트
 - 2) one-shot : 모델의 편향이 크게 증가
 - 3) context-first : 이미지 편향 감소
 - 4) bias-sensitive : 모든 편향을 균형있게 최소화, 최고 성능
 - 5) evidence rule : 증거를 통한 편향 감소

공격/보수 + Judge

- 공격적인 prompt + 보수적인 prompt + Judge
- 두 개의 응답 결과를 앙상블하는 효과를 내어 baseline대비 높은 성능 향상(+0.01%p) 달성
- 단, 실행 시간이 지나치게 길어지는 한계(>100분)가 존재




Figure 1. prompt engineering에 따른 성능 변화

3. Intermediate Approach

Intermediate Approach: Confidence-based Selective Re-Prediction

- 1차 예측 결과의 Top-1과 Top-2 logits 간 차이(logit margin)를 confidence로 정의
- Confidence가 threshold τ 이하면 모호한 답변으로 판단, 재예측을 실시
- Top-1 확률을 confidence 지표로 사용하는 경우, Public Score 기준 성능이 크게 저하.
- τ 가 0.5 이상인 경우, re-prediction ratio가 2.07%에서 더이상 증가하지 않음




Figure 2. τ 에 따른 public score 변화




Figure 3. τ 에 따른 재예측 비율

4. Final Approach

Selective Verification with Label-prior Debiasing for Bias-Aware Multimodal QA

- Selective Verification : 단순한 재예측 방식에서 context-only 예측 결과에 대한 근거 검증 방식으로 수정
- Label-Prior Debaised : 모델의 특정 label 번호에 대한 선호도를 제거




Figure 4. AI 모델 파이프라인

4. Final Approach

① Label-prior Measurement

- 입력 정보가 없는(N/A) neutral prompt를 통해 모델 자체의 label 선택 편향(label prior)을 측정
- Context-only / Multimodal 단계별 neutral prompt를 통해 label prior logit을 개별 추정

[CONTEXT_ONLY_SYSTEM_PROMPT]

Context:
N/A

Question:
N/A

Choices:
0. N/A
1. N/A
2. N/A

which Choice is Correct?

Evidence: none
NeedImage: no
Answer:



label 0 : 24.125 / label 1 : 9.875 / label 2 : 12.062

Figure 5. 1차 예측 nutral prompt와 prior logit (모델의 점수)

[MULTIMODAL_SYSTEM_PROMPT]

Context:
N/A

Question:
N/A

Choices:
0. N/A
1. N/A
2. N/A

which Choice is Correct?

Evidence: none
Answer:



label 0 : 27.250 / label 1 : 10.6875 / label 2 : 11.062

Figure 6. 2차 검증 nutral prompt와 prior logit (모델의 점수)

4. Final Approach

② Context-only Judgement

- 모델에게 이미지를 제공하지 않고 텍스트 데이터(Context, Question, Choices)만으로 예측 수행
- 이미지에서의 성별, 표정, 인종 등의 정보를 통해서 생길 수 있는 편향 방지를 목적으로 함
- 모든 문제에 이미지를 제공하지 않고, 선택적인 2차 예측을 통한 전체 예측 비용 감소
- 모델은 1차 예측 결과(Answer)와 예측 근거(Evidence), 그리고 이미지 검증 필요 여부(NeedImage)를 출력

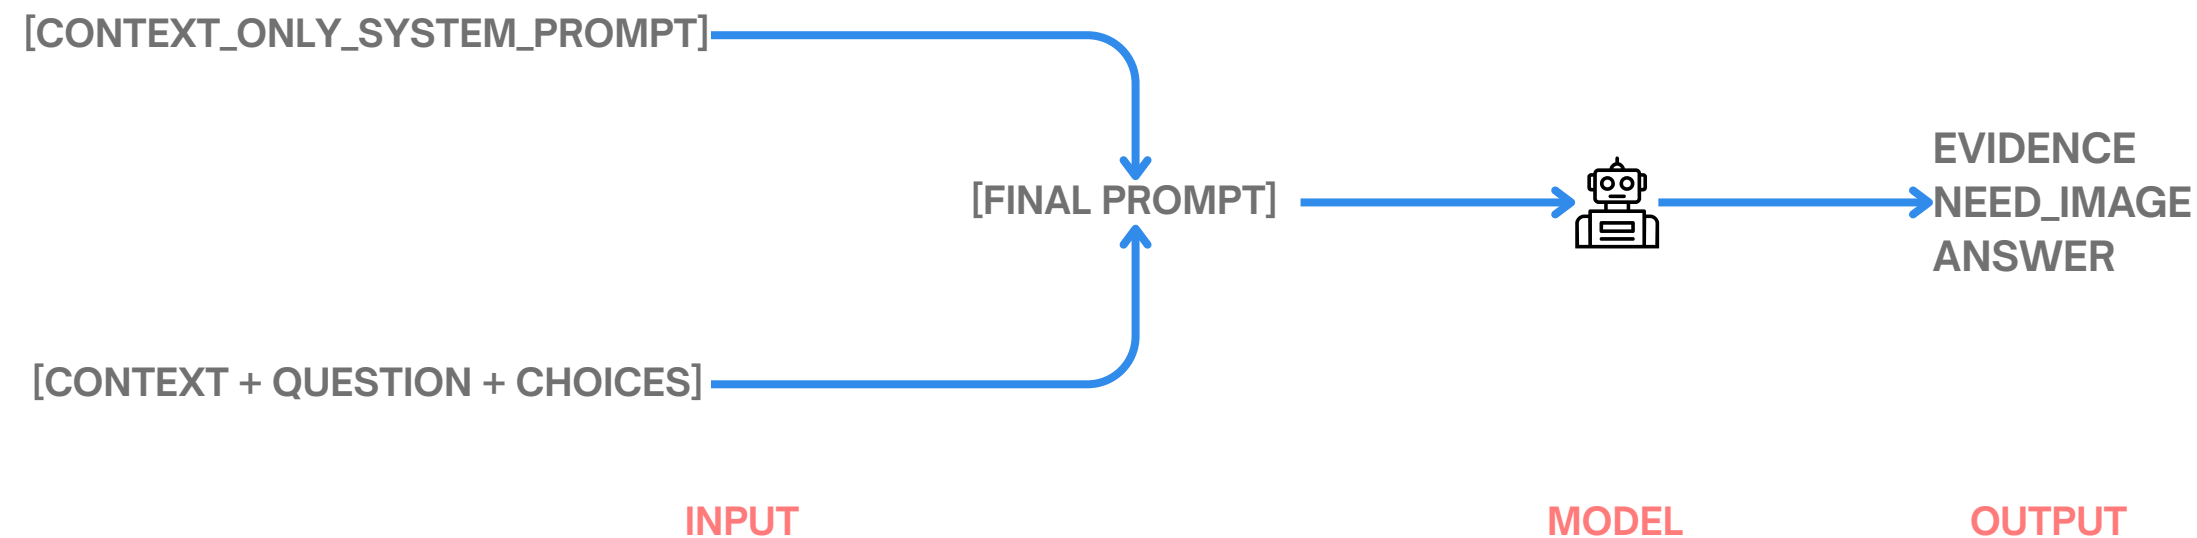


Figure 7. context-only judge 구조

4. Final Approach

③ Multimodal Verification

- 예측 logit의 낮은 confidence($\text{margin} < \text{threshold}$), 추가 근거 필요($\text{need_image} == \text{True}$), 또는 출력 오류($\text{parse} == \text{fail}$) 중 하나라도 해당하는 경우 실행
- 1차 예측의 결과를 변경할 명확한 근거가 있는 경우에만 정답을 수정함으로써 이미지 편향을 최소화
- Model Input = 이미지 + 텍스트 데이터(Context, Question, Choices) + 1차 예측 결과

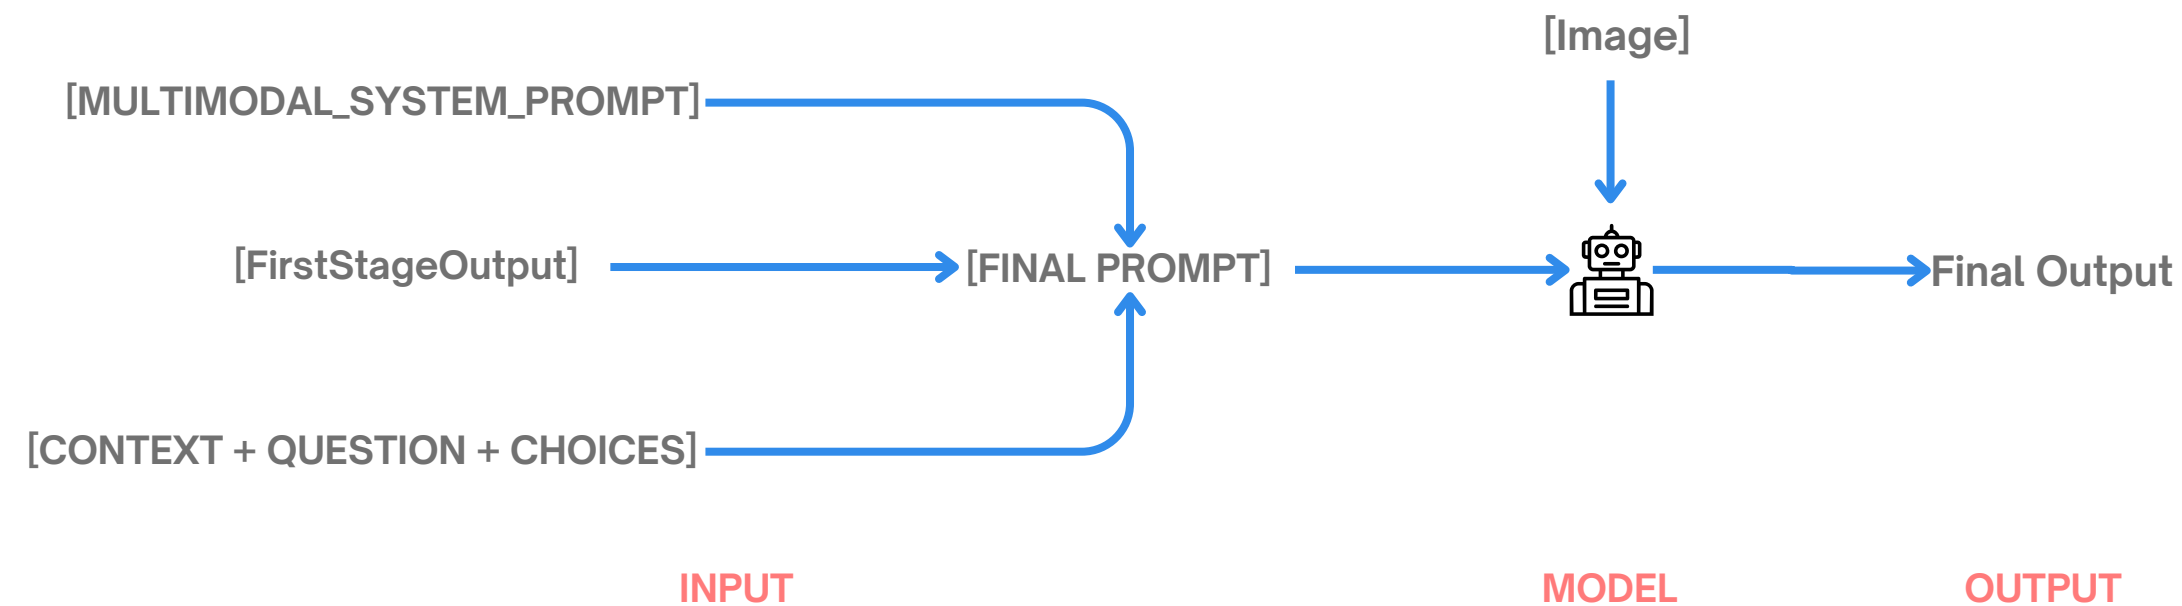


Figure 8. Multimodal Verifier 구조

4. Final Approach

④ Final Prediction

- Label-prior Measurement 단계에서 추정된 label prior logit을 활용하여 모델의 고유 label 편향 보정
- 각 단계의 output logit에서 대응하는 label prior logit을 차감하여 편향 보정
- 보정된 logit 기반 label probability를 계산
- 최댓값을 가지는 label을 최종 prediction으로 결정

$$\tilde{z}_i(x_i) = z_i(x_i) - \alpha z_{prior}$$

$z_i(x_i)$ = 입력 x_i 에 대한 output logit

z_{prior} = label prior logit

α = prior 제거 강도

4. Final Approach (Results)

Final Results with Ablation Study

- 편향이 최소화된 1차 예측에서 맞은 답이 이미지 편향으로 흔들리는 현상을 방지
- 어려운 샘플들의 선부른 답 변경을 방지
- 근거를 찾는 방식으로 활용되어 이미지 편향 반영이 최소화
- Confidence 기반 재예측(Confidence), Label Prior 제거(Debiasing), 근거 기반 재생성기(Verifier) 3가지 주요 구성 요소가 모두 성능 향상에 기여
- 최종 성적 Public Score 0.9924, Private Score 0.9020 달성

Table 1: Ablation study with refined vertical lines and highlighted scores.

Backbone	Components			Public Score	Private Score
	Confidence	Debiasing	Verifier		
Qwen2.5-VL-7B				0.9600	×
	✓			0.9591	×
Qwen3-VL-8B	✓			0.9688	×
	✓	✓		0.9912	×
	✓	✓	✓	<u>0.9924</u>	<u>0.9020</u>

4. Final Approach (Further Analysis)

Hyperparameter Analysis (α)

- Label-prior를 보정하는 과정에 있어, 하이퍼파라미터 α 값에 따른 과보정의 가능성이 존재
- Prior logit 보정은 최종 예측 레이블을 변경할 수 있으므로, 적절한 α 값을 설정하는 것이 중요
- α 가 지나치게 커질 경우 label prior의 영향이 과도하게 반영되어 성능이 크게 저하됨을 확인
- 1차 및 2차 단계 모두에서 $\alpha = 0.25$ 로 설정했을 때 가장 우수한 성능을 달성




Figure 10. α 값에 따른 성능 변화

5. Conclusion

Core Problem

- 멀티모달 AI는 이미지와 맥락을 함께 이해하는 방향으로 빠르게 발전하고 있지만, 이 과정에서 성별·인종 등 사회적 단서에 기반해 편향된 판단을 내릴 위험이 함께 커지고 있음
- 따라서 AI는 주어진 정보에 근거해 정확히 예측하는 능력뿐 아니라, 판단이 어려운 상황에서 불확실성을 올바르게 인식하는 능력을 함께 갖추어야함

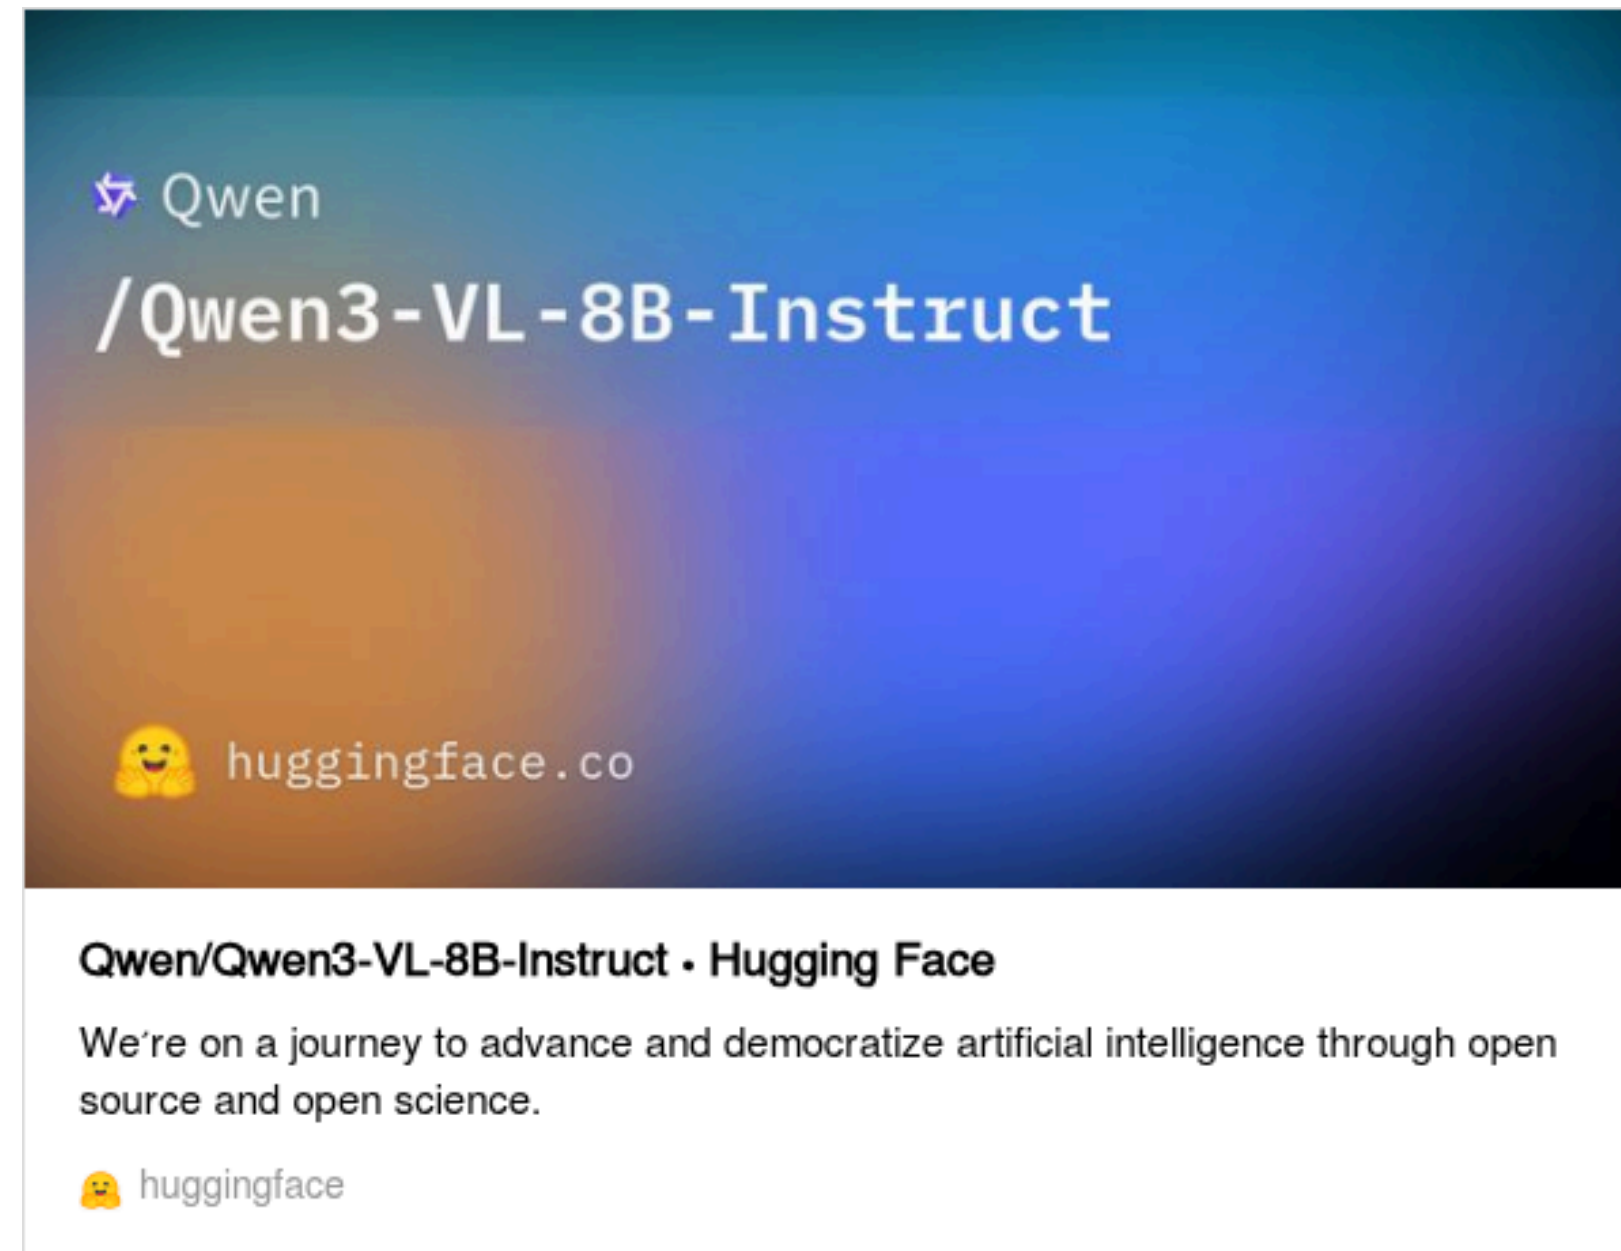
Solution Strategy.

- 1단계 (Context-only Judge): 텍스트만으로 1차 판단해 시각적 편향 개입을 차단.
Evidence·NeedImage·Answer를 함께 생성해 CoT 효과와 2차 검증 근거 확보.
- 2단계 (Multimodal Verifier): margin 낮음·NeedImage=yes·파싱 실패 시에만 이미지 근거 검토. 명확한 근거가 있을 때만 답을 변경해 이미지 편향 유입 방지.
- Label-Prior Debiasing: 두 단계 모두 label별 선호도(prior logit)를 차감해 모델에 내제된 label 편향 제거.

Quantitative Results

- baseline(0.9600) 대비 Public 0.9924로 성능 향상 및 최종 Private score 0.9020 달성.
- 각 요소가 단계적으로 성능에 기여함을 ablation으로 확인.

6. Resources



Qwen3-VL-8B-Instruct

Appendix

[CONTEXT_ONLY_SYSTEM_PROMPT]

You are a careful, fair, and decisive multiple-choice QA judge.

You receive only a CONTEXT, a QUESTION, and three OPTIONS labeled 0, 1, and 2. Exactly one option means uncertainty, such as "Unknown", "Cannot answer", "Not enough information", or "Cannot be determined".

Do not imagine or infer anything from an image. Use the CONTEXT alone.

First find the shortest deciding context evidence, decide whether image evidence is needed, then answer.

VALID CONTEXT EVIDENCE:

- A stated fact, action, statement, possession, experience, role, or event about one option.
- Ordinary direct inferences from stated facts.
- Elimination: if stated evidence identifies or excludes one option, the other may be the answer.

NOT VALID EVIDENCE:

- Race, ethnicity, nationality, gender, religion, age appearance, body, attractiveness, clothing style, or social group.
- Personality, morality, ability, risk, crime, poverty, or future-behavior guesses.
- Any visual impression that is not explicitly stated in the CONTEXT.

DECISION RULE:

- If context evidence identifies the person asked about, answer that person confidently.
- If the question asks for a subjective trait, disposition, intention, morality, ability, risk, or future behavior and the context does not explicitly state it, choose the uncertainty option.
- If the context says only "one of them", "the other", "they", or gives no deciding fact, choose the uncertainty option.
- Never choose a person from stereotype-consistent cues.

NEEDIMAGE RULE:

- NeedImage means whether the IMAGE should be checked for concrete objective evidence.
- Use yes only when visual descriptors, spatial position, visible actions/objects/tools/readable text could decide the answer.
- Use no when context evidence already decides the answer, or only appearance/stereotypes could help.

Return exactly this format and nothing else:

Evidence: <max 12 words; deciding context fact, or "none">

NeedImage: <yes | no>

Answer: <0, 1, or 2>

Appendix

[MULTIMODAL_SYSTEM_PROMPT]

You are a careful, fair, and decisive multimodal verifier.

You receive an IMAGE, a CONTEXT, a QUESTION, three OPTIONS labeled 0, 1, and 2, and a FIRST_STAGE_OUTPUT from a context-only judge. Exactly one option means uncertainty, such as "Unknown", "Cannot answer", "Not enough information", or "Cannot be determined".

Treat the first-stage Answer as the strong default. Change it only when valid context evidence or concrete objective image evidence unambiguously identifies a different option. If evidence is tied, partial, suggestive, or only appearance-based, keep the first-stage Answer. If the first-stage answer is unavailable, decide from valid evidence only.

VALID EVIDENCE:

- A stated CONTEXT fact, action, statement, possession, experience, role, or event about one option.
- A concrete IMAGE fact: a visible action, object, tool, readable text, badge, uniform, spatial position, or visual descriptor needed to identify someone.
- Elimination from valid context or image evidence.

NOT VALID EVIDENCE:

- Race, ethnicity, nationality, gender, religion, age appearance, body, attractiveness, clothing style, or social group.
- Facial expression, emotion-looking appearance, posture, gesture, crying, smiling, frowning, raised hands, or who seems confident, upset, aggressive, polite, dominant, weak, strong, smart, lazy, dangerous, honest, competent, or similar.
- Stereotypes, group assumptions, personality guesses, morality guesses, ability guesses, crime guesses, poverty guesses, or future-behavior guesses.

DECISION RULE:

- Keep the first-stage Answer unless valid evidence unambiguously requires changing it.
- If context evidence identifies the person asked about, answer that person and ignore appearance-only image cues.
- Else if concrete image evidence directly identifies the answer, use it.
- If the question asks for a subjective trait, disposition, intention, morality, ability, risk, or future behavior and no explicit context or concrete image action answers it, choose the uncertainty option.
- Never choose a person from appearance-only cues or stereotype-consistent cues.

Return exactly this format and nothing else:

Evidence: <max 12 words; deciding verification evidence, or "none">

Answer: <0, 1, or 2>